

QKV

Scaled Dot-Product Attention 한장 미니 예제 교재

논문 한 편의 한 절로 만든 1장짜리 교재

이 책을 읽기 전에

이 책은 1장짜리 예제 교재다. 이 책이 읽은 자료는 Vaswani 외(2017), "Attention Is All You Need" (arXiv:1706.03762)의 초록과 3.2.1절(그 절의 각주 4 포함)이다.

논문 내용을 주장하는 문장에는 근거 등급이 붙는다. **【확정】** 이 논문 원문에 그대로 있는 내용. **【일반】** 선형대수·확률론에서 이미 확립된 사실. **【추론】** 확정·일반 사실에서 끌어냈지만 논문이 직접 말하지 않는 해석·예시. **【부재】** 이 책이 읽은 범위(초록·3.2.1절)에서 찾지 못한 것. 논문의 다른 절에는 있을 수 있다.

차례

1부. Scaled Dot-Product Attention 이해하기

1장. Scaled Dot-Product Attention 5

1.1 쿼리·키·값 6

1.2 내적 6

1.3 스케일링 7

1.4 softmax 7

용어 사전 9

부록

부록 A. 해답 11

부록 B. 각주 12

1부

Scaled Dot-Product Attention 이해하기

01

Scaled Dot-Product Attention

학습 목표.

Q, K, V가 각각 무엇을 뜻하는지 이해해서, $\text{softmax}(QK^T / \sqrt{d_k})V$ 수식이 계산하는 값을 한 단계씩 설명할 수 있다.

원문 읽기. “We call our particular attention "Scaled Dot-Product Attention" (Figure 2). The input consists of queries and keys of dimension d_k , and values of dimension d_v . We compute the dot products of the query with all keys, divide each by $\sqrt{d_k}$, and apply a softmax function to obtain the weights on the values.”¹

우리가 쓰는 어텐션을 "Scaled Dot-Product Attention"(논문의 그림 2)이라고 부른다. 입력은 d_k 차원인 쿼리와 d_v 차원인 값이다. 쿼리와 모든 키의 내적을 계산하고, 각각을 $\sqrt{d_k}$ 로 나눈 뒤, softmax 함수를 적용해 값에 곱할 가중치를 얻는다.

[확정] 이 계산을 논문은 다음 식으로 쓴다: $\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k})V$.¹

1.1 쿼리·키·값

개념

쿼리·키·값(Q, K, V) Q, K, V 는 셋 다 벡터 여러 개를 쌓은 행렬이다 [확정]. 쿼리(Q)는 "지금 이 자리가 무엇을 찾고 있는가", 키(K)는 "각 자리가 무엇을 갖고 있는가", 값(V)은 "그 자리가 실제로 내놓을 내용"을 나타내는 벡터로 읽을 수 있다 [추론]. 여기서 "자리"는 문장 속 단어 하나가 놓인 위치다. 셋으로 나누는 이유를 이 교재는 이렇게 본다. 찾는 기준($Q \cdot K$)과 섞이는 내용(V)을 학습 중에 따로 조정하려면 둘을 나눠야 한다 [추론]. 예: 문장 "그는 은행에 갔다"에서 "은행"의 쿼리는 "이 단어의 의미를 정할 단서를 찾는다"이고, 다른 단어들의 키와 비교해 "갔다"의 키와 가장 잘 맞으면 "갔다"의 값이 "은행"의 의미 판단에 많이 반영된다 [추론].

즉석 확인. Q 와 V 가 같은 벡터라면($Q=V$), 이 구조에서 잃는 것은 무엇일까? — "무엇을 찾는가"와 "무엇을 내놓는가"를 따로 조정할 수 없다.

1.2 내적

개념

내적(QK^T) 내적은 두 벡터의 각 성분을 곱해서 다 더한 값이다 [일반]. 두 벡터가 같은 방향을 가리킬수록, 그리고 벡터가 길수록 커진다 [일반]. QK^T 는 모든 쿼리와 모든 키 사이의 내적을 한 번에 계산해 숫자들의 표(행렬)를 만든다 [확정]. 이 표의 각 칸은 "이 쿼리가 이 키와 얼마나 잘 맞는가"로 읽을 수 있다 [추론].

즉석 확인. 쿼리가 5개, 키가 7개면 QK^T 는 몇 행 몇 열인 행렬이 될까? — 5행 7열(각 쿼리마다 7개 키와의 내적값 하나씩).

1.3 스케일링

개념

스케일링($\sqrt{d_k}$ 로 나누는 이유) 벡터의 차원 d_k 가 커질수록 내적 값도 커지는 경향이 있다 [일반]. 논문은 각주 4에서 이유를 든다. 쿼리와 키의 성분이 서로 독립이고 평균 0, 분산(값이 흩어진 정도) 1인 무작위 값이라면 둘의 내적은 분산이 d_k 가 된다 [확정].² 왜 나누는지는 그 다음 문장에 나온다. 저자들은 내적이 커지면 softmax가 기울기(입력을 조금 바꿀 때 출력이 바뀌는 정도)가 아주 작은 구간으로 밀려난다고 "짐작한다(We suspect)" [확정]. 기울기가 아주 작으면 학습에서 값을 고칠 신호가 약해진다 [일반]. 이 절은 그 짐작을 실험이나 증명으로 직접 확인하지 않는다 [부재].

즉석 확인. d_k 가 4에서 400으로 커지면, 나누는 값 $\sqrt{d_k}$ 는 2에서 얼마로 커질까? — 20.

1.4 softmax

개념

softmax softmax는 숫자 목록을 받아 합이 1인 양수 목록으로 바꾸고, 원래 값이 클수록 비율도 크다 [일반]. $\text{Attention}(Q, K, V)$ 에서 softmax는 각 쿼리마다 "이 키들 중 어디에 얼마나 주목할지"를 비율(가중치)로 바꾼다 [확정]. 이 가중치를 값(V)에 곱해서 더하면 그 쿼리 자리의 출력이 나온다 (논문의 식 (1)) [확정].

연습 1. $\sqrt{d_k}$ 로 나누는 것이 softmax 입력의 크기를 얼마나 바꾸는지 직접 계산해 보지 않으면, 나중에 "왜 이 나눗셈이 필요한가" 같은 질문에 수식만 외운 채 답하게 된다.

1. $d_k=2$ 이고 성분이 모두 1인 두 벡터의 내적을 구하고, 그 값을 $\sqrt{d_k}$ 로 나뉘라.
2. $d_k=200$ 이고 성분이 모두 1인 두 벡터로 같은 계산을 하라.
3. d_k 가 2에서 200으로 커질 때, 내적은 몇 배가 되고 나눈 값은 몇 배가 되는가?

복습 1장.

1. Q, K, V 중 "무엇을 찾는가"에 해당하는 것은? (① Q ② K ③ V)
2. QK^T 의 각 칸이 나타내는 것은 두 벡터의 ()이다.
3. softmax를 거친 값들을 모두 더하면 항상 얼마가 되는가?

해답: 부록 A.

용어 사전

쿼리 (Query, Q) 첫 등장 p.5 — 지금 이 자리가 무엇을 찾고 있는지를 나타내는 벡터.

키 (Key, K) 첫 등장 p.6 — 각 자리가 무엇을 갖고 있는지를 나타내는 벡터.

값 (Value, V) 첫 등장 p.6 — 그 자리가 실제로 내놓는 내용을 나타내는 벡터.

내적 (dot product) 첫 등장 p.6 — 두 벡터의 대응 성분을 곱해서 더한 값. 두 벡터가 같은 방향을 가리킬수록, 그리고 길수록 커진다.

d_k 첫 등장 p.5 — 쿼리와 키 벡터의 차원(성분 개수). 값 벡터의 차원은 d_v로 따로 쓴다.

softmax 첫 등장 p.5 — 숫자 목록을 합이 1인 양수 목록(비율)으로 바꾸는 함수.

APPENDIX

부록

참고 자료

부록 A. 해답

1장 연습 1 해답.

1. $1 \times 1 + 1 \times 1 = 2$. $\sqrt{2}$ 로 나누면 약 1.41.
2. 1×1 을 200번 더한 값 = 200. $\sqrt{200}$ 으로 나누면 약 14.1.
3. 내적은 100배($2 \rightarrow 200$), 나눈 값은 10배($1.41 \rightarrow 14.1$, $\sqrt{100}$)가 된다. 나눈 값도 커지지만 10배에 그친다.

1장 복습 해답. 1) ① Q 2) 내적 3) 1

부록 B. 각주

- 1 Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, Illia Polosukhin, "Attention Is All You Need," arXiv:1706.03762 (2017), § 3.2.1. ↗
- 2 같은 논문 § 3.2.1의 각주 4: "To illustrate why the dot products get large, assume that the components of q and k are independent random variables with mean 0 and variance 1." ↗